

维学思辨星 · 性能基准指标汇总

真实链路实测：deepseek-v4-flash（评估/评语）+ qwen3-asr-flash（转写）

2026-08-14/15（代码版本 acb5e8d，完整报告见 docs/benchmarks/，可一键复现
backend/benchmark.py all）

1 关键数字总览

环节	核心指标	实测值
语音转写	45s 音频端到端耗时	3.1s（RTF 0.07×，产出 203 字）
转写准确率	22 条样本平均逐字一致率（去标点）	99.0%（中位 100.0%，最低 91.4%）
批量评估	27 条（9 学生 × 3 辩题）	27/27 成功、0 错误，26.4s/条
评语草稿	逐学生生成	5.4s/条（批量接口 6.1s/条）
成本	27 评估 + 9 评语	≈ 0.15 元/节课
教师侧	人工批改 vs AI 审阅确认	3 分钟/条 → ≤1 分钟/条（省约 67%）
校准记忆	45 维 AI-教师一致率 A/B	27% → 40%，AI 偏高 30 → 22

2 语音转写

2.1 端到端转写（45s 示例音频）

指标	实测值
音频时长	44.99s（1.38MB，16k 单声道 WAV）
端到端墙钟（上传 + ASR + 入库）	3.13s
实时率 RTF	0.070×
转写产出字数	203 字
语速	4.5 字/s

2.2 转写准确率（22 条样本）

口径：字符级一致率（diffib），主指标为去标点后的逐字一致率；样本为 18 条队友语音 + 3 条
豆包儿童音色 + 1 条示例课堂音频（592.4s），覆盖干净单说话人场景。

逐文件明细见附录 A。

指标	实测值
样本数	22 条 (音频总时长 592.4s)
ASR 总耗时	58.8s
平均一致率 (去标点)	99.0%
中位一致率 (去标点)	100.0%
最低一致率 (去标点)	91.4% (儿童音色, 差异多为语气词插入)
平均一致率 (含标点)	96.5%

3 批量评估 (27 条 = 9 学生 × 3 辩题)

口径: 串行执行真实 LLM 调用, 后台任务逐条评估; 耗时为本机墙钟。

指标	实测值
需要评估条数	27
完成条数	27
成功 (含评分)	27
错误 / 跳过	0 / 0
总耗时	713.7s
平均	26.4s/条
单条 min / 中位 / max	12.5s / 24.0s / 82.5s
单条 P95	54.2s
评估成本粗估 (token)	111,610 (输入 84,622 + 输出 26,988 字符粗估)

3.1 AI 置信度分布 (27 条)

置信度	条数	占比
certain_good	18	66.7%
certain_weak	7	25.9%
uncertain	2	7.4%

4 评语草稿生成 (9 名学生)

5 成本

5.1 官方账单核对 (DeepSeek, 2026-08-14)

5.2 字符级 token 粗估

口径: 中文 ≈ 1 token/字符; 实际约 1.25 token/字符 (字符粗估约比实际低 27%), 以官方账单为成本基准。ASR (qwen3-asr-flash) 走百炼控制台另行计费, 不在本账单内。

学生	耗时 (s)	字数	150-250 合规
小雨	4.87	258	否
豆豆	4.67	266	否
萌萌	6.23	244	是
小明	6.84	272	否
婷婷	4.41	284	否
浩浩	5.80	293	否
小杰	6.17	323	否
佳怡	4.55	298	否
大伟	4.77	289	否

指标	实测值
总耗时（逐学生，9 条）	48.30 s
平均	5.37 s/条
单条 min / 中位 / max	4.407 s / 4.865 s / 6.836 s
批量接口总耗时	54.47 s（折算 6.05 s/条）
字数合规率（150-250）	1/9
模板化开头	0/9
占位文本（无批改记录）	0/9

6 教师侧效率（手测补充，2026-08-14）

注意：评语为草稿阶段倍率，教师定稿耗时未计入；人工批改为单人秒表实测，建议后续补测 2-3 条取平均。

7 校准记忆 A/B（机制演示）

口径：同 9 条教师已批改作答，同日两次评估（deepseek-v4-flash）；参照为团队演示教师终评（模拟教师）；B 轮注入 5 条校准记录（取自 A 轮观测的 AI→ 教师偏差）。

7.1 分维度一致率（45 维）

8 AI 与教师一致率基线（无校准，9 条已批改作答）

定位说明：AI 输出为评分初稿，教师逐维确认是设计意图（教师决策门），而非替代教师终评。

9 口径与边界

- 教师一致率参照为团队演示教师终评（模拟教师），非真实教师大规模验证；校准 A/B 为机制演示（few-shot 收敛），不是真实教师验证结论。

指标	数值
请求数	89 次（含此前两次失败尝试）
Token 总量	161,653
账单金额	¥0.18
单次完整成功跑（27 评估 + 9 评语 $\approx$ 45 次调用）	$\approx$ ¥0.15 / 节课

环节	输入字符	输出字符	token 粗估
批量评估（27 条）	84,622	26,988	111,610
评语生成（9 条）	13,500	2,527	16,027

- 转写准确率样本为合成语音（TTS），覆盖干净单说话人场景；真实家庭/课堂噪声未覆盖。
- 耗时为单机墙钟测量，单次测量为主；成本为官方账单核对 + 字符粗估双口径。
- 评语字数目标区间 150–250，当前实测普遍偏长（258–323 字），作为草稿供教师编辑定稿。
- 勿与旧数混用：8/11 的 515s $\approx$ 19s/条为 qwen-plus 时期数据，本轮模型见报告头部。

A 附录 A：转写准确率逐文件明细（22 条）

文件	音频 (s)	参考字数	转写字数	一致率 (去标点)	一致率 (含标点)	ASR (s)
01_s1_t2_ 小雨	26.0	103	103	100.0%	95.7%	4.49
02_s1_t3_ 小雨	23.0	81	81	98.8%	96.1%	2.39
03_s2_t2_ 豆豆	31.0	114	114	99.1%	96.1%	3.02
04_s2_t3_ 豆豆	17.2	62	62	100.0%	97.8%	2.24
05_s3_t2_ 萌萌	15.5	63	63	100.0%	97.1%	2.82
06_s3_t3_ 萌萌	45.2	140	140	100.0%	95.9%	3.19
07_s4_t1_ 小明	17.9	63	63	100.0%	98.6%	2.61
08_s4_t3_ 小明	20.0	75	75	98.7%	97.6%	2.38
09_s5_t1_ 婷婷	32.0	109	109	100.0%	97.5%	2.58
10_s5_t3_ 婷婷	22.0	87	87	100.0%	96.4%	2.24
11_s6_t1_ 浩浩	21.0	86	86	98.8%	97.9%	2.47
12_s6_t3_ 浩浩	29.5	147	147	100.0%	99.1%	2.69
13_s7_t1_ 小杰	18.0	63	63	100.0%	98.6%	2.70
14_s7_t2_ 小杰	36.5	103	103	100.0%	96.6%	3.29
15_s8_t1_ 佳怡	30.0	109	109	100.0%	97.5%	2.53
16_s8_t2_ 佳怡	26.2	97	97	99.0%	95.5%	2.31
17_s9_t1_ 大伟	19.0	81	81	98.8%	97.7%	2.80
18_s9_t2_ 大伟	22.4	112	112	99.1%	94.8%	3.02
小朋友 1	44.0	102	107	96.7%	94.4%	2.96
小朋友 2	43.0	112	119	97.0%	93.7%	3.13
小朋友 3	53.0	65	75	91.4%	90.5%	2.91

文件	音频 (s)	参考字数	转写字数	一致率 (去标点)	一致率 (含标点)	ASR (s)
sample_class_audio	45.0	185	185	100.0%	98.8%	—

对比项	人工	AI 辅助（实测）	提升
教师批改 1 条作答	约 3 分钟（单人秒表）	AI 初稿审阅确认 ≤ 1 分钟	节省约 67%
全流程单条	约 180s	26.4s + ≤ 60 s ≈ 86 s	约 2 倍
教师撰写 1 条评语	3-5 分钟（企业确认基线）	AI 草稿 5.4s	草稿阶段约 33-56 倍

指标	A 无校准	B 校准记忆
9 条整体完全一致	0/9	0/9
45 维完全一致	12/45（27%）	18/45（40%）
≤ 1 级占比（45 维）	25/45（56%）	22/45（49%）
AI 偏高次数	30	22
AI 偏低次数	3	5
单轮总耗时	180.9s	304.1s（提示词变长，+68%）
错误 / 跳过	0/0	0/0

维度	A 无校准	B 校准记忆
立意	4/9（44%）	5/9（56%）
选材	3/9（33%）	3/9（33%）
结构	0/9（0%）	1/9（11%）
语言	0/9（0%）	1/9（11%）
视角	5/9（56%）	8/9（89%）

维度	可比条数	一致条数	一致率
立意	9	3	33%
选材	9	5	56%
结构	9	1	11%
语言	9	2	22%
视角	9	4	44%
整体五维完全一致	9	0	0%
至少一维一致	9	8	89%